PCA y K-Means para datos de tráfico en Python

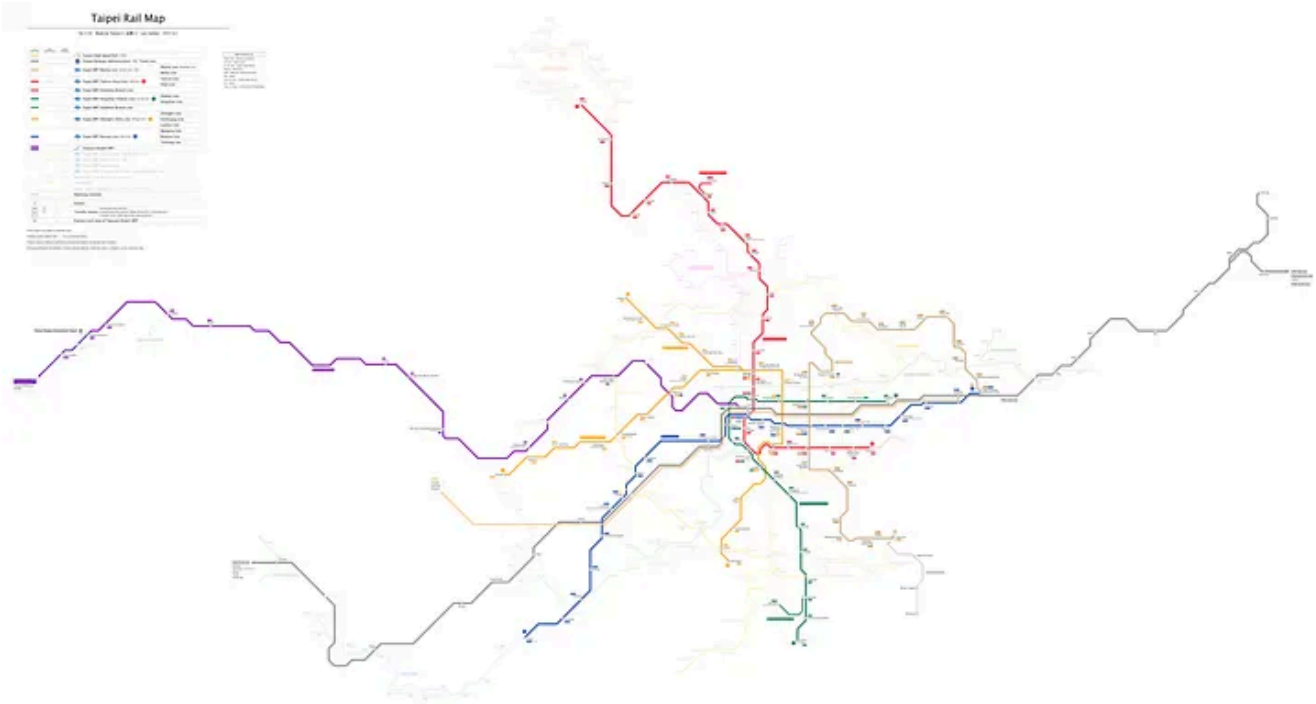
Reducir la dimensionalidad y agrupar las estaciones de MRT de Taipei en función del tráfico por hora



Beth Ou Yang Seguir

8 minutos de lectura · 7 de mayo de 2024

342 6



Mapa ferroviario de Taipéi (basado en los estándares de romanización introducidos), incluyendo THSR, TRA, MRT de Taipéi y otras líneas. Imagen de Taiwan J.

El análisis de componentes principales (PCA) se ha utilizado en datos de tráfico para detectar anomalías, pero también se puede utilizar para capturar los patrones del historial de tráfico de una estación de tránsito, de forma similar a lo que hace con los datos de compra de un cliente.

. . .

En este artículo repasaremos:

1. ¿Qué trucos hace PCA?
2. ¿Qué podemos hacer después de aplicar PCA?
3. **¡ Hora de jugar** !
   Consulta nuestro conjunto de datos:
   Sistema de Tránsito Rápido del Metro de Taipéi, Datos de Tráfico por Hora.
   El código completo también está incluido en el conjunto de datos de Kaggle mencionado anteriormente.
4. Uso de PCA en datos de tráfico por hora
5. Agrupamiento en el resultado de PCA
6. Información sobre el tráfico del MRT de Taipei
7. Conclusiones clave

. . .

1. ¿Qué trucos hace el PCA?

En resumen, PCA resume los datos encontrando combinaciones lineales de características, lo que puede considerarse como tomar varias fotografías de un objeto 3D y ordenará naturalmente las imágenes desde la más representativa hasta la menos representativa antes de entregárselas.

Con nuestros datos originales como entrada, el PCA tendría dos resultados útiles: **Z** y **W.** Al multiplicarlos, obtenemos los datos de reconstrucción, que son los datos originales, pero con una pérdida de información tolerable (ya que redujimos la dimensionalidad).

Explicaremos estas 2 matrices de salida con nuestros datos en la siguiente práctica.

2. ¿Qué podemos hacer después de aplicar el PCA?

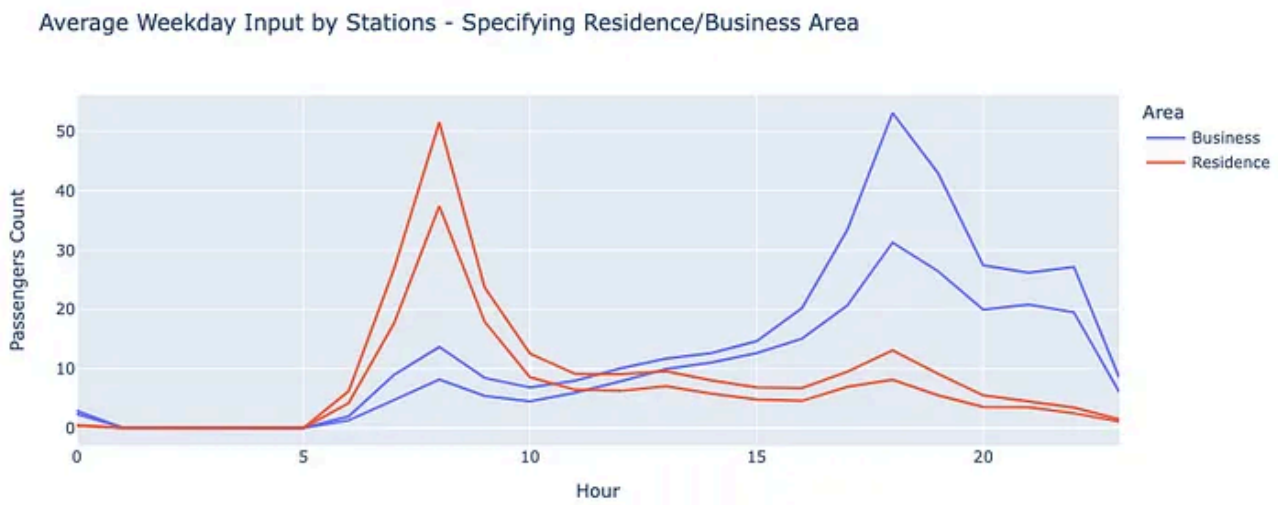
Después de aplicar PCA a nuestros datos para reducir la dimensionalidad, podemos usarlo para otras tareas de aprendizaje automático, como agrupamiento, clasificación y regresión.

En el caso del MRT de Taipéi, más adelante en este artículo, realizaremos una agrupación de datos con dimensiones más bajas. Algunas dimensiones pueden interpretarse como la proporción de pasajeros en diferentes momentos del día, como la mañana, el mediodía y la noche. Estas estaciones comparten proporciones similares de pasajeros durante el día y se considerarían parte del mismo grupo (¡sus patrones son similares!).

3. ¡Eche un vistazo a nuestro conjunto de datos de tráfico!

Los datos que utilizamos aquí son Taipei Metro Rapid Transit System, datos de tráfico por hora , con columnas: `date, hour, origin, destination, passenger_count`.

En nuestro caso, solo mantendré los datos de los días de semana, ya que hay patrones más interesantes entre diferentes estaciones durante los días de semana, como por ejemplo las estaciones en áreas residenciales pueden tener más viajeros que ingresan durante el día, mientras que por la noche, las estaciones en áreas comerciales pueden tener más personas ingresando.



Las estaciones en áreas residenciales pueden tener más viajeros ingresando durante el día.

El gráfico superior muestra la tendencia horaria del tráfico en cuatro estaciones diferentes (la cantidad de pasajeros que entran a la estación). Las dos líneas en rojo son Xinpu y el Mercado Yongan, ubicadas en zonas concurridas de Nueva Taipéi. Por otro lado, las dos líneas en azul son el Ayuntamiento de Taipéi y Zhongxiao Fuxing, donde se ubican la mayoría de las empresas y se desarrollan sus actividades.

Las tendencias reflejan tanto la naturaleza de estas áreas como de estas estaciones, y podemos notar que la diferencia es más obvia cuando comparamos sus tendencias durante las horas de viaje (de 7 a 9 am y de 17 a 19 pm).

4. Uso de PCA en datos de tráfico por hora

¿Por qué reducir la dimensionalidad antes de realizar más tareas de aprendizaje automático?

Hay dos razones principales:

1. **A medida que aumenta el número de dimensiones** , todos los puntos de datos parecen ser dispersos y diferentes en muchos sentidos, lo que se denominaría “la maldición de la dimensionalidad”.

2. Debido a la naturaleza **de alta dimensión** de los datos de tráfico, es **difícil visualizarlos e interpretarlos** .

Al aplicar el ACP, podemos identificar las horas en las que las tendencias de tráfico de las diferentes estaciones son más evidentes y representativas. Intuitivamente, según el gráfico mostrado anteriormente, podemos asumir que las horas entre las 8:00 y las 18:00 podrían ser suficientemente representativas para agrupar las estaciones.

¿Recuerdas que mencionamos las útiles matrices de salida, Z y W, del PCA en la sección anterior ? Aquí las interpretaremos con nuestro caso MRT.

Datos originales, X

	0	1	5	6	7	8	9	10	11	12	...	14	15	16	17	18	19	20	21	22	23
Banxin	0.00	0.0	0.0	0.02	0.09	0.15	0.09	0.04	0.04	0.04	...	0.03	0.04	0.05	0.07	0.12	0.07	0.04	0.03	0.03	0.01
Beimen	0.01	0.0	0.0	0.01	0.05	0.11	0.05	0.03	0.04	0.04	...	0.05	0.05	0.06	0.10	0.14	0.09	0.05	0.04	0.03	0.01
Beitou	0.00	0.0	0.0	0.03	0.10	0.15	0.08	0.06	0.05	0.05	...	0.05	0.04	0.05	0.07	0.08	0.04	0.03	0.03	0.02	0.01
Cailiao	0.00	0.0	0.0	0.03	0.13	0.23	0.11	0.05	0.04	0.04	...	0.03	0.03	0.04	0.06	0.06	0.03	0.02	0.02	0.02	0.01
Chiang_Kai-Shek_Memorial_Hall	0.00	0.0	0.0	0.01	0.03	0.06	0.04	0.03	0.04	0.06	...	0.05	0.05	0.08	0.15	0.15	0.07	0.04	0.05	0.04	0.01
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
Zhongxiao_Fuxing	0.01	0.0	0.0	0.00	0.02	0.03	0.02	0.02	0.03	0.04	...	0.05	0.06	0.07	0.09	0.12	0.10	0.09	0.09	0.07	0.03
Zhongxiao_Xinsheng	0.01	0.0	0.0	0.01	0.02	0.05	0.03	0.03	0.03	0.04	...	0.05	0.05	0.07	0.11	0.16	0.10	0.07	0.07	0.05	0.02
Zhongyi	0.00	0.0	0.0	0.02	0.07	0.09	0.05	0.04	0.05	0.05	...	0.04	0.04	0.06	0.10	0.14	0.10	0.05	0.02	0.01	0.01
Zhongyuan	0.00	0.0	0.0	0.01	0.04	0.08	0.04	0.03	0.02	0.03	...	0.02	0.02	0.03	0.08	0.28	0.17	0.05	0.03	0.02	0.01
Zhuwei	0.00	0.0	0.0	0.03	0.12	0.15	0.09	0.06	0.06	0.05	...	0.05	0.04	0.05	0.07	0.07	0.05	0.03	0.02	0.02	0.01

116 rows × 21 columns

- Índice: estaciones
- Columna: horas
- Valores: la proporción de pasajeros que ingresan en la hora específica (para cada estación: #pasajeros / #total de pasajeros)

Con tal X, podemos aplicar PCA mediante el siguiente código:

```
de sklearn.decomposition importar PCA
```

```
n_componentes = 3
 pca = PCA(n_componentes=n_componentes)

X_tran = StandardScaler().fit_transform(X)

pca.fit(X_tran)
```

Aquí, especificamos que el parámetro **n_components** sea 3, lo que implica que PCA extraerá los 3 componentes más significativos para nosotros.

Tenga en cuenta que es como " *tomar varias fotos de un objeto 3D y ordenarlas de la más representativa a la menos representativa* ", y seleccionamos las 3 mejores. Por lo tanto, si establecemos **n_components** en 5, obtendremos 2 imágenes más, pero las 3 mejores se mantendrán.

Salida PCA, matriz W

W puede considerarse como los pesos de cada característica (es decir, horas) con respecto a nuestras “imágenes” o, más específicamente, **componentes principales** .

```
pd.set_option( 'precisión' , 2 )

W = pca.components_
W_df = pd.DataFrame(W, columnas=hour_mapper.keys(), índice=[ f'PC_ {i} '  para i
W_df.round ( 2 ) .style.background_gradient(cmap= 'Azules' )
```

	0	1	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23
PC_1	0.22	0.18	-0.04	-0.26	-0.28	-0.28	-0.29	-0.28	-0.21	-0.09	-0.07	0.08	0.15	0.15	0.22	0.23	0.24	0.28	0.27	0.25	0.23
PC_2	0.04	0.14	0.05	-0.01	-0.06	-0.07	-0.02	0.12	0.29	0.41	0.43	0.42	0.37	0.31	0.15	-0.19	-0.21	-0.06	0.04	0.05	0.02
PC_3	0.42	0.30	0.08	0.19	0.14	0.14	0.14	0.10	-0.04	-0.12	0.04	0.03	-0.03	-0.25	-0.35	-0.28	-0.17	0.09	0.23	0.30	0.40

Para nuestros 3 componentes principales, podemos ver que PC_1 pesa más en las horas de la noche, mientras que PC_2 pesa más en el mediodía y PC_3 pesa más en las horas de la mañana.

Salida PCA, matriz Z

Podemos interpretar la matriz **Z** como la representación de las estaciones.

```
Z = pca.fit_transform(X)

# Nombra las PC según los datos de la matriz W
 Z_df = pd.DataFrame(Z, index =origin_mapper.keys(), columns=[ 'Night' , 'Noon'

# Observa las estaciones que demostramos anteriormente
 Z_df = Z_df.loc[[ 'Zhongxiao_Fuxing' , 'Taipei_City_Hall' , 'Xinpu' , 'Yongan_M
Z_df.style.background_gradient(cmap= 'Blues' , axis= 1 )
```

	Morning	Noon	Night
Zhongxiao_Fuxing	2.84	1.77	6.95
Taipei_City_Hall	1.38	-1.04	6.19
Xinpu	0.68	-0.22	-3.44
Yongan_Market	0.73	-0.32	-4.14

En nuestro caso, como hemos interpretado la matriz W y comprendido el significado latente de cada componente, podemos asignar nombres a las PC.

La matriz Z de estas 4 estaciones indica que las dos primeras tienen una mayor proporción de horas nocturnas, mientras que las otras dos tienen más horas matutinas. Esta distribución también confirma los hallazgos de

nuestro análisis de datos de energía (EDA) (recuerde el gráfico de líneas de estas 4 estaciones en la parte anterior).

5. Agrupamiento en el resultado de PCA con K-Means

Después de obtener el resultado del PCA, agrupemos aún más las estaciones de tránsito según sus patrones de tráfico, que están representados por tres componentes principales.

En la última sección, la matriz Z tiene representaciones de las estaciones con respecto a la noche, el mediodía y la mañana.

Agruparemos las estaciones en función de estas representaciones, de modo que las estaciones del mismo grupo tengan distribuciones de pasajeros similares entre estos tres períodos.

Hay muchos métodos de agrupamiento, como K-Means, DBSCAN, agrupamiento jerárquico, etc. Dado que el tema principal aquí es ver la conveniencia de PCA, omitiremos el proceso de experimentar qué método es más adecuado y optaremos por **K-Means** .

```
de sklearn.cluster importar KMeans

# Ajustar la matriz Z al modelo K-Means
 kmeans = KMeans(n_clusters= 3 )
kmeans.fit(Z)
```

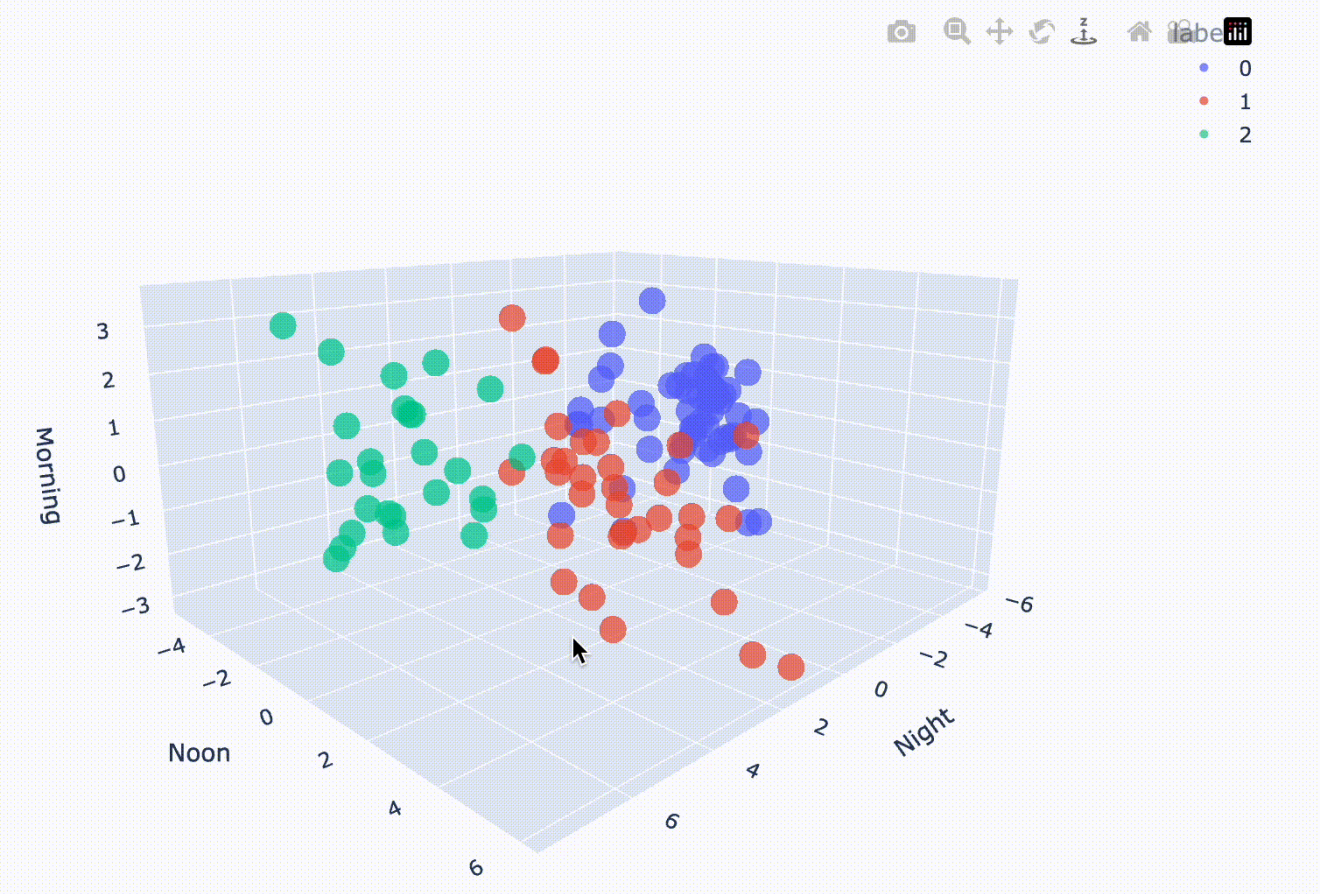
Después de ajustar el modelo K-Means, visualicemos los clústeres con un diagrama de dispersión 3D realizado por plotly .

```
import plotly.express como px

cluster_df = pd.DataFrame(Z, columns=[ 'PC1' , 'PC2' , 'PC3' ]).reset_index()
```

```
# Convierte las etiquetas de números enteros a cadenas,
# de modo que puedan tratarse como números discretos en el gráfico.
 cluster_df[ 'etiqueta' ] = kmeans.labels_
cluster_df[ 'etiqueta' ] = cluster_df[ 'etiqueta' ].astype( str )

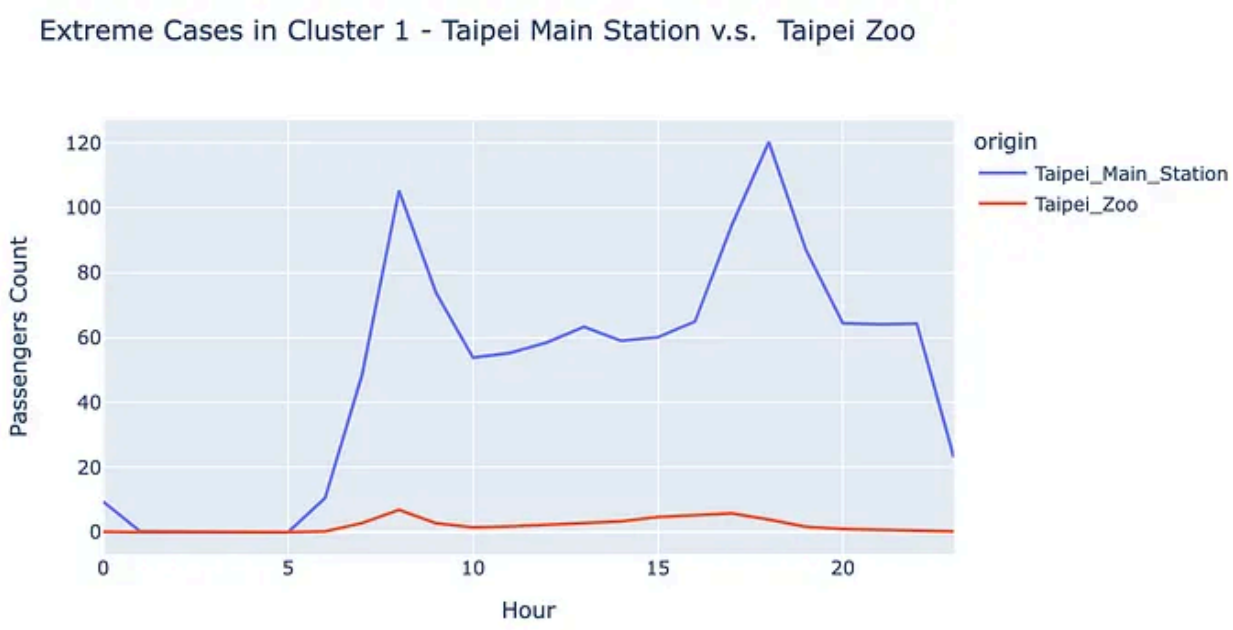
fig = px.scatter_3d(cluster_df, x= 'PC1' , y= 'PC2' , z= 'PC3' ,
                        color= 'etiqueta' ,
                        hover_data={ "origen" : (pca_df[ 'índice' ])},
                        labels={
                            "PC1" : "Noche" ,
                            "PC2" : "Mediodía" ,
                            "PC3" : "Mañana" ,
                            },
                       opacidad= 0.7 ,
                       tamaño_máx= 1 ,
                       ancho = 800 , alto = 500
                      ).update_layout(margin= dict (l= 0 , r= 0 , b= 0 , t= 0 )
                     ).update_traces(tamaño_del_marcador = 5 )
```



6. Información sobre el tráfico del MRT de Taipéi: Resultados de la agrupación



- **Clúster 0** : Más pasajeros durante el día, por lo que puede ser el grupo "zona de estar".
- **Cluster 2** : Más pasajeros por la tarde, por lo que podría ser el grupo "zona comercial".
- **Grupo 1** : Tanto de día como de noche, las estaciones están repletas de gente, y es más complejo explicar la naturaleza de estas estaciones, ya que podría haber diferentes razones para cada una. A continuación, analizaremos dos casos extremos de este grupo.



Por ejemplo, en **el Clúster 1** , la estación con mayor afluencia de pasajeros, la Estación Principal de Taipéi, es un importante centro de tránsito en Taipéi, donde los viajeros pueden hacer transbordo desde autobuses y trenes hasta el MRT. Por lo tanto, el patrón de alto tráfico durante la mañana y la tarde es evidente.

Por el contrario, la estación del Zoológico de Taipéi también se encuentra en el Grupo 1, pero no se trata de una situación en la que haya mucha gente tanto de día como de noche. De hecho, no hay mucha gente en ninguno de los dos períodos porque hay pocos residentes en la zona y la mayoría de los ciudadanos rara vez visitan el Zoológico de Taipéi entre semana.

Los patrones de estas dos estaciones no son muy similares, a pesar de estar en el mismo conglomerado. Es decir, el conglomerado 1 podría contener demasiadas estaciones que, en realidad, no son similares. Por lo tanto, en el futuro, tendríamos que ajustar los hiperparámetros de K-Means, como el número de conglomerados, y métodos como la **puntuación de silueta** y **el método del codo** serían útiles.

. . .

Conclusión

En resumen,

1. La aplicación de PCA en datos de tráfico para reducir la dimensionalidad se puede implementar extrayendo tres períodos importantes (mañana, mediodía y tarde) de un total de 21 horas hábiles **.**
2. Los resultados de PCA son matrices W y Z, donde Z puede verse como las representaciones de las estaciones con respecto a los componentes principales (períodos de tiempo), y W puede pensarse como las representaciones de los componentes principales (períodos de tiempo) con respecto a las características originales (horas).

3. Considerar la matriz W puede ayudarnos a comprender el significado latente de cada componente principal.
4. Se pueden utilizar métodos de agrupamiento en la salida del PCA, la matriz Z.

> *Tenga en cuenta que aquí omitimos el ajuste de EDA y de hiperparámetros para centrarnos en el tema de este artículo, pero en realidad son importantes.*

¡Gracias por leer hasta aquí!
¡Que tengas un maravilloso viaje en línea en Taipéi! 🫶

. . .

Lecturas adicionales

- Hiperparámetros de KMeans explicados con ejemplos , Sujeewa Kumaratunga PhD
- ¿Cómo combinar el análisis de componentes principales (PCA) y la agrupación en clústeres de K-medias en Python? , Elitsa Kaloyanova

Referencia

- Apuntes de clase de DSCI 563, Maestría en Ciencias de Datos de la UBC, Varada Kolhatkar
- Agrupamiento de K-medias en datos de alta dimensión. , shivangi singh
- La maldición de la dimensionalidad: una “maldición” para el aprendizaje automático , Shashmi Karanam

A menos que se indique lo contrario, todas las imágenes son del autor.