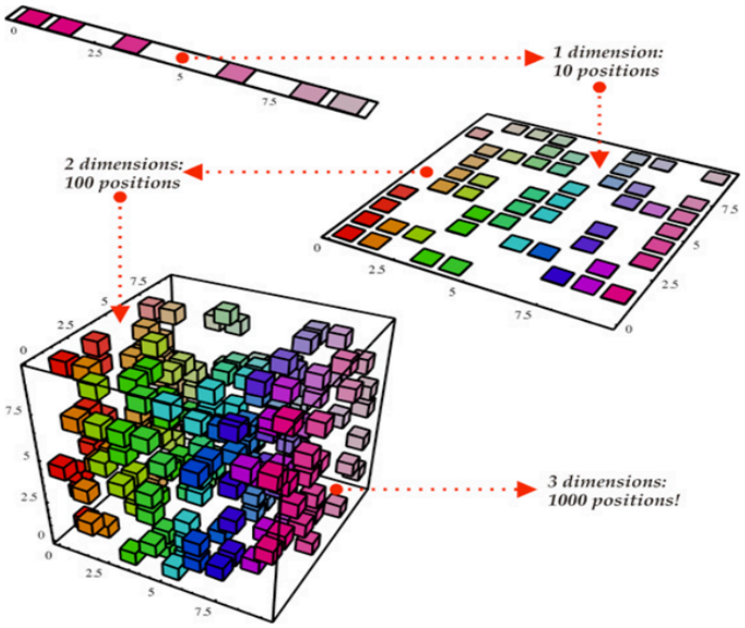
Reducción de la dimensionalidad

La ***reducción de dimensionalidad*** es una técnica de aprendizaje no supervisado que se utiliza cuando la cantidad de características (o dimensiones) en un conjunto de datos determinado es demasiado alta. Reduce la cantidad de entradas de datos a un tamaño manejable y al mismo tiempo preserva la integridad de los datos. A menudo, esta técnica se utiliza en la etapa de preprocesamiento de datos, como cuando los codificadores automáticos eliminan el ruido de los datos visuales para mejorar la calidad de la imagen.
Es una técnica que se utiliza para mejorar el entrenamiento (al tener menos variables) y mejorar la visualización de los datos (sólo podemos graficar hasta 3 dimensiones).
Uno de los métodos más empleados es el análisis de componentes principales, también conocido como PCA por sus siglas en inglés. El cual se aplica a variables numéricas.

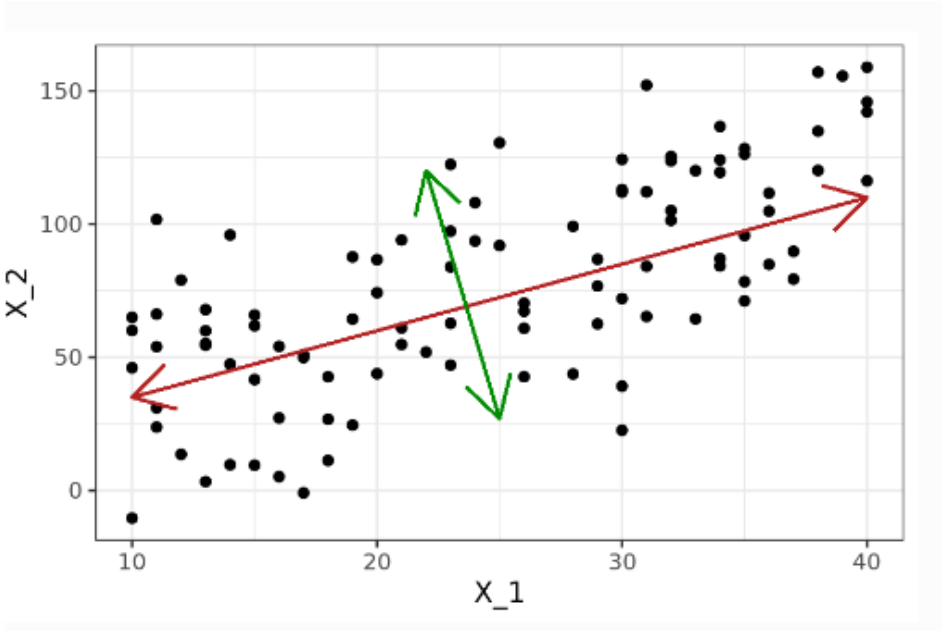


Reducción de la dimensionalidad

Análisis de componentes principales (PCA)

El Análisis de Componentes Principales (PCA, por sus siglas en inglés) es una técnica de reducción de la dimensionalidad que se utiliza en machine learning y estadística para simplificar conjuntos de datos complejos , manteniendo la mayor parte de su información original.
PCA se aplica a variables numéricas y busca transformar un conjunto de datos en un nuevo sistema de coordenadas donde las nuevas variables (o componentes principales) no estén correlacionadas y se ordenan en función de la varianza que explican. Es decir, se reducen las dimensiones (p) del conjunto de datos reteniendo la mayoría de la variación de ellos en vectores llamados componentes principales.
Se desea una pérdida mínima de información al proyectar las n instancias sobre un espacio de dimensión q con q < p tal que la dispersión en el espacio proyectado q debe ser máxima.

La primera componente principal captura la mayor cantidad de la varianza de los datos, la segunda componente captura la segunda mayor cantidad de la varianza, y así sucesivamente.
El número de componentes principales que puede ser obtenido de un conjunto de datos es igual al número de dimensiones (variables) que tenga dicho conjunto.
Desde el punto de vista geométrico es un cambio de ejes en la representación (proyección)



Vectores de Componentes principales de 2 dimensiones

Este método permite transformar los atributos originales, x1, x2,.. xm en nuevos atributos, f1, f2,.. fp de tal manera que:

- Los nuevos atributos son independientes entre sí
- Los primeros f´ tienen más relevancia (más contenido informacional) que los últimos
- La transformación asegura que si ignoramos los últimos p-k atributos estaremos descartando la información menos relevante

Con pocos componentes se puede explicar la mayor parte de la información (varianza) que contienen las variables del conjunto de datos original. Con variables con alta dependencia es frecuente que con menos del 20% de las variables se explique más del 80% de la variabilidad original.
Como dijimos anteriormente esto facilita el entrenamiento, como también permite visualizar gráficamente conjuntos de datos que no podríamos por su alta dimensionalidad.
Cada componente principal debe ser una combinación lineal de las variables originales. La información contenida en la variable se ve reflejada en la componente.
La eficacia y la interpretabilidad de PCA pueden variar en función de la correlación entre las variables originales:

Variables Correlacionadas: Cuando las variables originales están correlacionadas, PCA puede ser especialmente útil, ya que identifica las direcciones en las que los datos tienen la



mayor variabilidad. Esto significa que PCA puede resaltar patrones y estructuras en los datos, lo que facilita la reducción de la dimensionalidad sin perder mucha información.
Variables Independientes: Si las variables originales son independientes entre sí, es decir, no están correlacionadas, PCA todavía puede usarse para reducir la dimensionalidad, pero puede ser menos efectiva en términos de la varianza explicada.

Las componentes principales son no correlacionadas dos a dos, eliminando información redundante y deben tener varianza máxima, de ese modo se asegura que contienen el máximo de información posible.

Estandarización

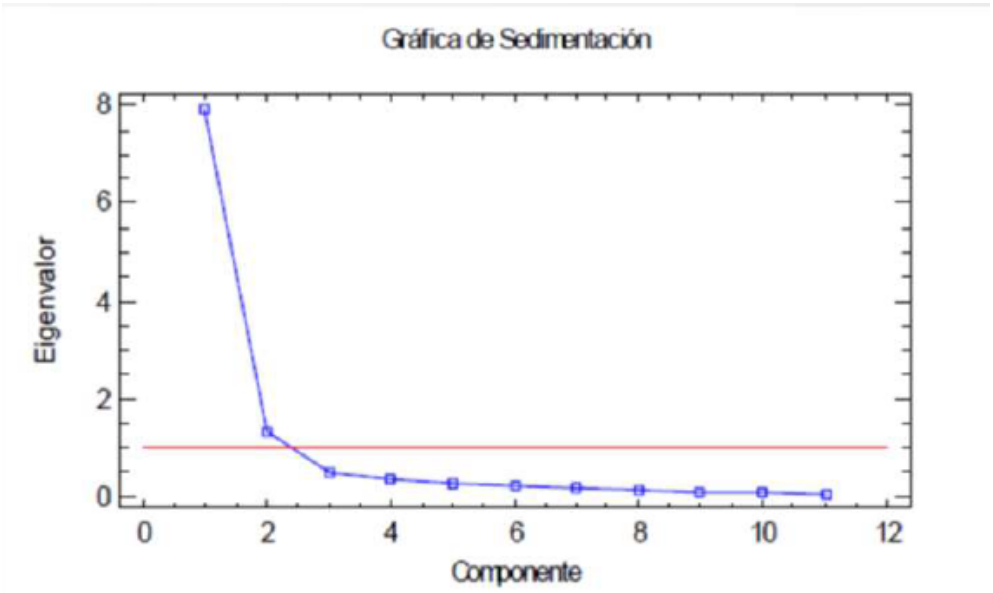
Es habitual que las distintas variables de un conjunto de datos se midan en distintas unidades. Como el desvío estándar se mide en las mismas unidades que la variable, una unidad de desvío estándar para en una variable no nos dice la misma información que una unidad de desvío estándar para otra variable medida en otra unidad.
Esto puede llegar a ser un problema a la hora de utilizar PCA, ya que las escalas de las variables pueden ser muy distintas. Las componentes principales se alinearán entonces a los ejes de las variables con mayor rango de escala, que a lo mejor no son las variables de mayor variabilidad respecto a su valor medio. Es por esto que se recomienda estandarizar los datos previo a implementar el PCA.

Selección de componentes principales

Cada dato de entrada es una combinación lineal de los p vectores componentes principales.
Los componentes principales se clasifican en orden “significación” decreciente (peso)
Debido a que los componentes están clasificados, el tamaño de los datos se puede reducir eliminando las componentes débiles (aquellas con menor varianza explicada).
Utilizando las componentes principales más significativas es posible reconstruir una buena aproximación de los datos originales con menos dimensiones.
La cantidad de componentes principales a elegir puede realizarse con diferentes criterios:

Criterio de la varianza explicada: Se suman los porcentajes de varianza explicada asociada a cada factor y nos quedamos con aquellos que sumen un porcentaje prefijado. Mínimo 50%, algunos autores recomiendan ≥ 80%

Criterio del codo: Las componentes, ordenadas de mayor a menor, se representan en un gráfico de la varianza asociada a cada factor, el gráfico de sedimentación. El gráfico suele mostrar la clara ruptura entre la pronunciada pendiente de los factores más importantes y el descenso gradual de los restantes (los sedimentos). Nos quedaremos con los primeros.



Fuentes:

https://www.ibm.com/es-es/topics/unsupervised-learning
https://www.kaggle.com/code/ismaelalpaso/principalcomponentsanalysis-acp-spanish
Material de la Maestría en Ciencia de Datos e Innovación Empresarial UCaece -2020