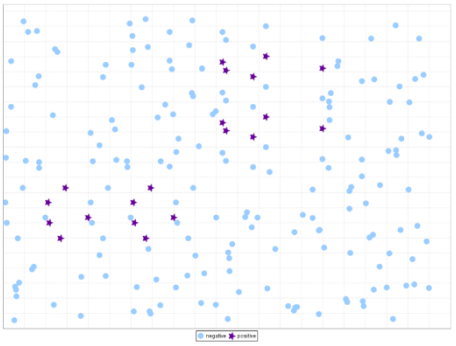
Conjuntos de Datos desbalanceados

Un conjunto de datos desbalanceado es aquel en el que el número de observaciones pertenecientes a un grupo o clase es significativamente mayor que el número de observaciones pertenecientes a otras clases. Como se muestra en la figura, algunas de las clases son muy frecuentes y otras muy raras. Esto sucede por la naturaleza del problema en sí, por la forma en que se recopilan los datos o por la forma en que se procesan los datos.

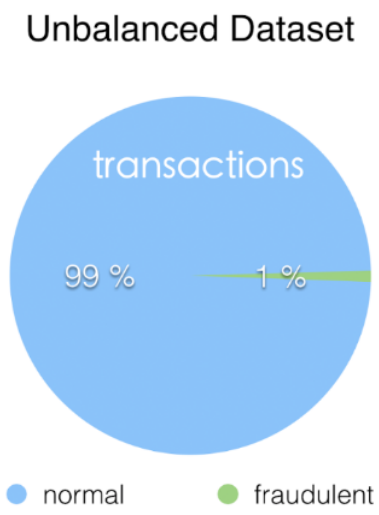


Las observaciones de la clase minoritaria, a pesar de ser esporádicas, pueden tener un gran impacto en nuestros resultados (por ejemplo, la detección de una enfermedad rara, la ocurrencia de un fraude) y suele ser la que tiene el mayor interés ya que implica un gran costo cuando no está bien clasificada.

Los conjuntos de datos desbalanceados pueden sesgar los resultados de un modelo de machine learning hacia la clase mayoritaria (en general es la clase "negativa"), teniendo como resultado un modelo en el cual hay una tasa de clasificación errónea más alta para las instancias de clase minoritaria que conforma los ejemplos "positivos" que se desean encontrar.

También sucede que la mayoría de los algoritmos de aprendizaje estándar consideran un conjunto de entrenamiento equilibrado, esto puede generar modelos de clasificación subóptimos, es decir, una buena cobertura de los ejemplos mayoritarios, mientras que los minoritarios se clasifican erróneamente. Por lo tanto, esos algoritmos, que obtienen un buen comportamiento en el marco de la clasificación estándar, no necesariamente logran el mejor rendimiento para los conjuntos de datos desequilibrados.

Algunos ejemplos de conjuntos de datos desbalanceados son:



Un conjunto de datos de detección de fraude, en donde hay muchas más transacciones legítimas que fraudulentas.

Un conjunto de datos de detección de spam, en donde hay muchas más direcciones de correo electrónico legítimas que direcciones de correo electrónico de spam.

Un conjunto de datos para detección de enfermedades, en donde la gran mayoría de las instancias corresponden a una persona sana.

Un conjunto de datos usado para churn, en donde la gran mayoría de los clientes permanecen con el servicio (clase "No-Churn").

Tecnicas de Oversampling y Undersampling

Cuando tenemos conjuntos de datos desbalanceados, y queremos aplicar una algoritmo de clasificación, las tecnicas de muestreo de datos nos permiten modificar las instancias de training para obtener una distribución de clases más o menos equilibrada, a fin de permitir a los clasificadores desempeñarse de manera similar a la clasificación estándar (SMOTE es una de las técnicas utilizadas para este caso).
Se dice que es un enfoque externo, ya que se pre-procesan los datos para disminuir el efecto del desequilibrio de clase.

Estas se pueden clasificar en :

1) Oversampling: Consiste en generar datos sintéticos con unas características parecidas a las observaciones de la clase minoritaria. Se crea un superconjunto del dataset original replicando algunas instancias o creando nuevas instancias a partir de las existentes.
Como inconveniente, puede suceder que aumente la probabilidad de que se produzca un overfitting, ya que hace copias exactas de las instancias existentes.

2) Undersampling: Consiste en reducir el número de casos de la categoría más abundante con el fin de obtener un conjunto de datos balanceado. Se crea un subconjunto del dataset original al eliminar instancias de la clase mayoritaria.
El principal inconveniente es que se pueden descartar datos potencialmente útiles, que podrían ser importantes para el proceso de aprendizaje.

3) Métodos híbridos: combinan ambos enfoques de muestreo.



Hay otros métodos más sofisticados como la "Sinthetic minority oversampling technique" que es uno de los enfoques más reconocidos en esta área porque crea nuevos ejemplos de clases minoritarias al interpolar varias instancias de esa clase agregándolas al dataset de training.

Además del enfoque externo, otros enfoques para tratar datasets desbalanceados pueden ser:

Internos: se crean nuevos algoritmos o modifican los existentes para tener en cuenta el problema del desequilibrio de clase.

Mixtos: son soluciones de aprendizaje sensibles al costo que incorporan los enfoques de datos (externos) y de nivel algorítmico (interno) que asumen costos de clasificación errónea de la clase minoritaria más altos y luego buscan minimizar los errores de alto costo. Estas técnicas se adaptan con frecuencia a dominios desbalanceados, ya sea modificando el algoritmo de aprendizaje en conjunto con el enfoque de nivel de datos para pre-procesar los datos antes de la etapa de aprendizaje de cada clasificador.
En general, en problemas en donde tenemos conjuntos de datos desbalanceados, seguramente será más interesante reconocer las instancias positivas minoritarias en lugar de las negativas. Por lo tanto, el costo al clasificar erróneamente una instancia positiva debe ser mayor que el costo de clasificar erróneamente una instancia negativa.
Los únicos que pueden proporcionar estos valores de costos de clasificación errónea son los expertos en el dominio del problema .

Evaluación en dominios desequilibrados

Los criterios de evaluación son un factor clave para determinar el rendimiento del modelo de clasificación, y esto es particularmente difícil para problemas de clasificación con conjuntos de datos desequilibrados, ya que la mayoría de las métricas estándar que se utilizan ampliamente suponen una distribución de clases equilibrada.

Como vimos en unidades anteriores, tradicionalmente se utiliza *accuracy* para medir la performance del algoritmo. Pero en el marco de los conjuntos de datos desequilibrados, el *accuracy* ya no es una medida adecuada porque no distingue entre el número de ejemplos correctamente clasificados de diferentes clases.
Por ejemplo, si quisieramos predecir las transacciones fraudulentas en un banco, y tenemos sólo una transacción fraudulenta entre un total de 1000, el modelo podría predecir todas las transacciones como no fraudulentas. Nos devolvería una accuracy de 99.9 %, lo cual nos podría parecer una métrica muy buena, cuando en realidad no detectó la transacción fraudulenta, por lo tanto no es un buen modelo para ese caso.

Como regla general, *accuracy* no es una buena métrica para evaluar algoritmos con datasets desbalanceados.

En dominios desequilibrados, la evaluación del rendimiento de los clasificadores debe llevarse a cabo utilizando métricas específicas para tener en cuenta la distribución de la clase que nos interesa.



Una métrica de clasificación utilizada en estos escenarios es la curva ROC o análisis ROC (Característica Operativa del Receptor), y es muy recomendada en el caso de datasets desbalanceados porque permite la visualización de la compensación entre los beneficios o TPR (tasa de verdaderos positivos) y los costos o FPR (tasa de falsos positivos).

Fuentes:

Analysis of preprocessing vs. cost-sensitive learning for imbalanced classification. Open problems on intrinsic data characteristics. Victoria López, Alberto Fernández, , Jose G. Moreno-Torres, Francisco Herrera

Material de la Maestría en Ciencia de Datos e Innovación Empresarial UCaece -2020