Algoritmos Ensamblados

La técnica de ensamble de algoritmos consiste en combinar varios modelos al mismo tiempo para solucionar un mismo problema con el objetivo de obtener mejores predicciones. Son una herramienta muy útil para mejorar el rendimiento de los modelos de aprendizaje automático.
Existen diferentes tipos de ensamblado, siendo los más utilizados:

Bagging: se construyen múltiples modelos de un mismo algoritmo, con diferentes subconjuntos del dataset de entrenamiento, la predicción final se realiza mediante estadísticas simples para combinar las predicciones (por ejemplo la media de las predicciones de todos los modelos).

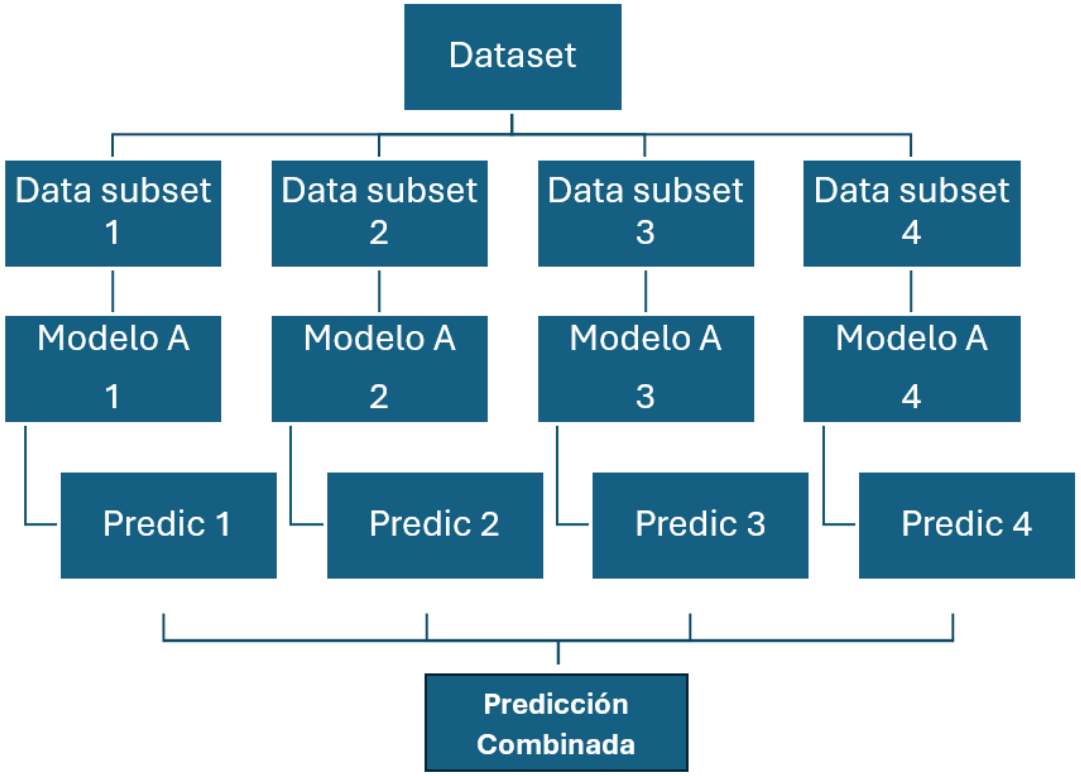
Boosting: se construyen múltiples modelos de un mismo algoritmo ensamblados secuencialmente, cada modelo aprende a corregir los errores de predicción del modelo anterior en la secuencia.

Voting: se construyen múltiples modelos de distintos algoritmos, y se usan estadísticas simples para combinar las predicciones (por ejemplo la media de las predicciones de todos los modelos).

Bagging

Es un método de ensamblado en el que se construyen múltiples modelos de un mismo algoritmo, con diferentes subconjuntos del dataset de entrenamiento, la predicción final se realiza mediante estadísticas simples para combinar las predicciones.
En este método se crean subconjuntos de los datos originales de manera aleatoria y con reposición, es decir una instancia puede aparecer en más de un subconjunto.
Cada modelo es entrenado de manera independiente con cada subconjunto de datos. A estos modelos se los conoce como “modelos débiles” o “aprendices débiles”.
La predicción final se realiza combinando las predicciones de los modelos débiles. Si se trata de un problema de regresión, la predicción final se obtendrá por promedio de las predicciones de los modelos débiles; si el problema es de clasificación el predicción final se corresponderá con la predicción que haya hecho la mayoría de los modelos débiles.

Bagging



Random Forest es una extensión de bagging, ya que utiliza este método agregándole la aleatoriedad en la selección de las variables para la construcción de los diferentes árboles.

Ventajas:

1. Son fáciles de implementar , hay librerías que proveen diferentes métodos de ensamblado utilizando bagging.
2. Reducen la varianza: lo que resulta útil en datasets afectados por valores outliers.

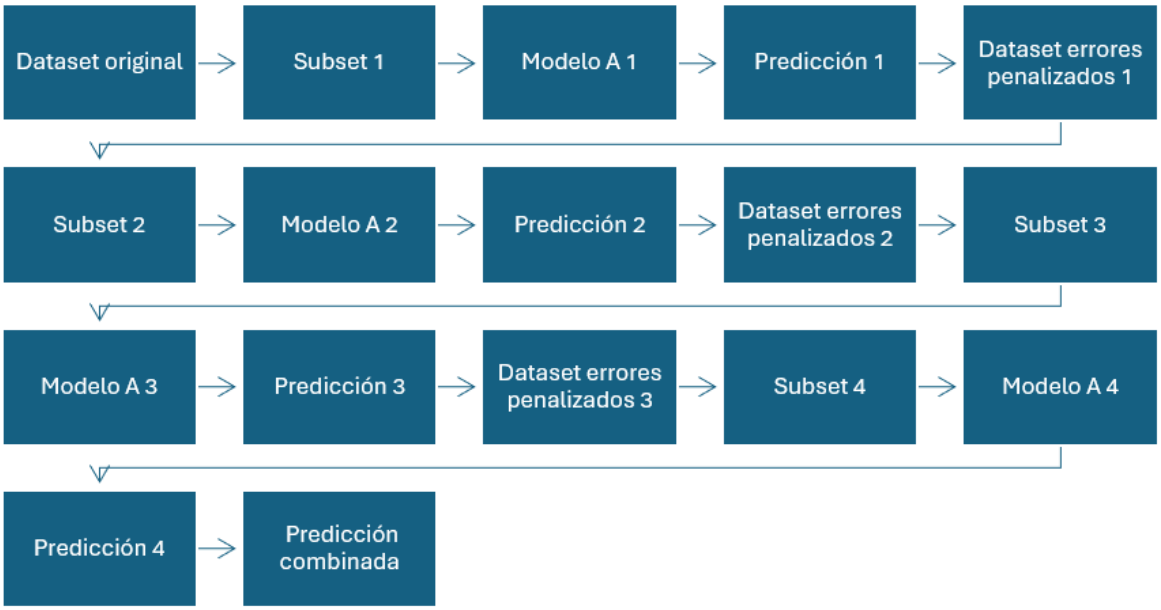
Desventajas

1. Pérdida de interpretabilidad: son difíciles de interpretar y obtener información adicional respecto del negocio.

Boosting

Es un método de ensamblado en el que se construyen múltiples modelos de un mismo algoritmo ensamblados secuencialmente, cada modelo aprende a corregir los errores de predicción del modelo anterior en la secuencia.

En este método se crean un subconjunto de los datos originales de manera aleatoria se entrena un modelo con ese subconjunto de datos. Se evalúan los resultados y se penalizan los errores.
Se actualiza el dataset con esas penalizaciones y se vuelve a crear un subconjunto aleatorio para entrenar el modelo débil siguiente el cual intentará compensar los errores cometidos por el modelo anterior.
La predicción final se realiza combinando las predicciones de los modelos débiles. Si se trata de un problema de regresión, la predicción final se obtendrá por promedio de las predicciones de los modelos débiles; si el problema es de clasificación la predicción final se corresponderá con la predicción que haya hecho la mayoría de los modelos débiles.



Boosting

Ventajas:

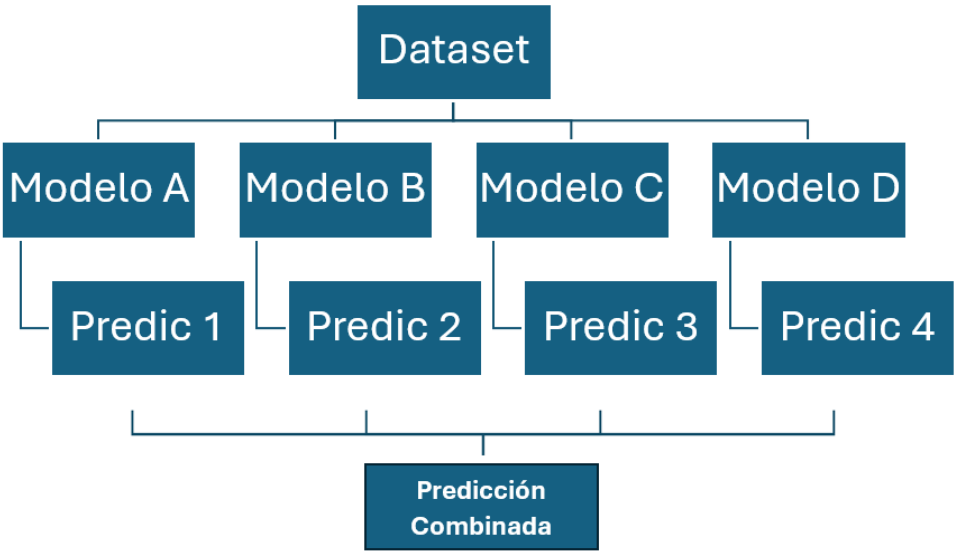
1. Son fáciles de implementar , hay librerías que proveen diferentes métodos de ensamblado utilizando boosting.
2. Reducen el sesgo: se van mejorando las observaciones con cada iteración.
3. Eficiencia computacional: al ejecutarse secuencialmente no se utilizan recursos computacionales adicionales.

Desventajas

1. Pérdida de interpretabilidad: son difíciles de interpretar y obtener información adicional respecto del negocio.
2. Cálculo intensivo: cada modelo débil se basa en los resultados de su predecesor lo que hace que sean más lentos de entrenar.

VOTING

Es un método de ensamblado en el que se construyen múltiples modelos de distintos algoritmos de clasificación, la predicción final se corresponderá con la predicción que haya hecho la mayoría de los modelos en caso de clasificación o el promedio de las predicciones hechas en caso de regresión..
Es una manera sencilla de combinar los resultados de diferentes modelos para fortalecer la predicción.
Se crean dos o más modelos independientes que se entrenan con el dataset original. Luego se evalúan los resultados y el resultado final se corresponderá con la predicción que haya hecho la mayoría de los modelos o su media.
Si bien parecería similar a Bagging tiene dos claras diferencias: todos los modelos se entrenan con el mismo dataset y pueden ensamblarse diferentes algoritmos.



REFERENCIAS

https://towardsdatascience.com/ensemble-learning-bagging-and-boosting-23f9336d3cb0

https://www.ibm.com/es-es/topics/bagging
https://www.ibm.com/es-es/topics/boosting

